

Classification automatique des types d'anémie à partir d'analyses sanguines (CBC)

Réalisé par : Jaouad El Morabit | Encadré par : Pr Ismail El Batteoui

Dataset : kaggle.com/datasets/ehababoelnaga/anemia-types-classification | Notebook :
kaggle.com/code/jaouadelmorabit/projet-anemie

1. Introduction

L'anémie et les troubles hématologiques se diagnostiquent à partir de la numération de la formule sanguine (CBC), qui mesure une quinzaine d'indicateurs relatifs aux globules rouges, aux globules blancs et aux plaquettes. L'objectif de ce projet est d'appliquer les algorithmes d'apprentissage supervisé étudiés en cours pour prédire automatiquement le type de diagnostic à partir de ces indicateurs. La problématique posée est la suivante : à partir des 14 variables sanguines d'un patient, peut-on prédire de manière fiable son diagnostic parmi 9 classes possibles ?

Le jeu de données utilisé (« Anemia Types Classification », Kaggle) rassemble 1281 patients décrits par 14 variables numériques. Il présente deux caractéristiques importantes : un fort déséquilibre entre les classes (de 336 cas sains à seulement 11 cas de « Leukemia with thrombocytopenia ») et des valeurs aberrantes (erreurs de saisie) corrigées lors du prétraitement par bornage médical, afin de préserver les classes rares.

2. Modèles utilisés

Quatre algorithmes de classification supervisée ont été entraînés sur les mêmes données (découpage train/test stratifié 80/20, variables normalisées) :

- **Régression logistique** : modèle linéaire estimant la probabilité d'appartenance à chaque classe.
- **K plus proches voisins (K-NN)** : classe attribuée par vote majoritaire des k voisins les plus proches.
- **Arbre de décision** : suite de règles « si... alors... » divisant les données en groupes homogènes.
- **Forêt aléatoire (Random Forest)** : ensemble d'arbres agrégés par vote, réduisant le surapprentissage.

3. Résultats

Modèle	Accuracy (test)	Validation croisée (5 plis)
Régression logistique	0,852	0,855
K-NN (optimisé, k = 8)	0,790	0,767
Arbre de décision	0,996	0,989
Random Forest (optimisé)	0,984	0,981




Figure 1 — Comparaison de l'accuracy des quatre modèles sur le jeu de test.

4. Meilleur modèle et justification du choix

Le modèle retenu est la **forêt aléatoire (Random Forest)**. Bien que l'arbre de décision seul atteigne une accuracy légèrement supérieure (0,996), la forêt aléatoire constitue le meilleur choix pour les raisons suivantes :

- **Robustesse** : en agrégeant les prédictions de nombreux arbres, la forêt aléatoire est moins sensible au bruit et généralise mieux qu'un arbre unique, dont le score très élevé pourrait dépendre de particularités du jeu de test.
- **Performance élevée et stable** : accuracy de 0,984 sur le test et 0,981 en validation croisée, avec un écart-type faible — les performances ne dépendent donc pas d'un découpage chanceux.
- **Supériorité sur les modèles linéaires et par distance** : la régression logistique (0,852) et le K-NN (0,790) sont nettement dépassés, car ils s'adaptent mal à un problème à 9 classes en haute dimension.
- **Fiabilité par classe** : la matrice de confusion (Figure 2) montre une diagonale très marquée ; les rares erreurs surviennent entre classes médicalement voisines.

Nuance importante : l'accuracy globale (98 %) masque une faiblesse sur la classe ultra-rare « Leukemia with thrombocytopenia » (11 exemples seulement). Le macro F1-score (0,94), qui traite toutes les classes à égalité, est une mesure plus honnête. Des techniques de rééquilibrage (SMOTE, pondération) constituent une piste d'amélioration.

Matrice de confusion - Random Forest

True label \ Predicted label	Healthy	Iron deficiency anemia	Leukemia	Leukemia with thrombocytopenia	Macrocytic anemia	Normocytic hypochromic anemia	Normocytic normochromic anemia	Other microcytic anemia	Thrombocytopenia
	Healthy	Iron deficiency anemia	Leukemia	Leukemia with thrombocytopenia	Macrocytic anemia	Normocytic hypochromic anemia	Normocytic normochromic anemia	Other microcytic anemia	Thrombocytopenia
Healthy	67	0	0	0	0	0	0	0	0
Iron deficiency anemia	0	37	0	0	0	1	0	0	0
Leukemia	1	0	8	0	0	0	0	0	0
Leukemia with thrombocytopenia	0	0	1	1	0	0	0	0	0
Macrocytic anemia	0	0	0	0	4	0	0	0	0
Normocytic hypochromic anemia	0	0	0	0	0	56	0	0	0
Normocytic normochromic anemia	0	0	0	0	0	0	54	0	0
Other microcytic anemia	0	1	0	0	0	0	0	11	0
Thrombocytopenia	1	0	0	0	0	0	0	0	14

Figure 2 — Matrice de confusion de la forêt aléatoire sur le jeu de test.